

Calibración de sensores IoT de material particulado mediante análisis de métricas y ventanas móviles

Fernando Quintana González^{*}
Isabella María Ucrós Muñoz^{}**

Universidad Industrial de Santander
CL. 9 Cra 27, Bucaramanga, Santander

26 de Septiembre del 2025

Índice

1. Introducción	2
2. Metodología	3
3. El experimento y los resultados	3
3.1. Distancia, ventanas móviles y errores	4
3.2. Calibración	5
3.3. Alcance predictivo, criterios de validez y extensión del modelo	7
3.3.1. Comportamiento local	7
3.3.2. Extensión del modelo	8
4. Conclusiones y Recomendaciones	10
5. Referencias	10

Resumen

El presente trabajo aborda la calibración de sensores IoT destinados a la medición de material particulado fino (PM_{25}), en comparación con datos de referencia oficiales (AMB). Dado que los sensores IoT cambian su respuesta por factores ambientales, se desarrolló una metodología de calibración basada en el concepto de métrica y el uso de ventanas móviles para establecer pares comparables de datos. Los datos fueron organizados, depurados y filtrados para llegar a una correspondencia continua entre ambos conjuntos. Se aplicaron diferentes configuraciones

^{*} e-mail: fernando2241359@correo.uis.edu.co

^{**} e-mail: isabella2240675@correo.uis.edu.co

de ventana y paso para obtener promedios locales y pares comparables entre ambas fuentes, evaluando la similitud mediante el error cuadrático medio (RMSE) y su versión relativa. La configuración óptima fue la ventana de 4 horas con paso de 2 horas.

Con estos pares se ajustó un modelo lineal que transforma valores IoT en estimaciones cercanas a los de referencia. La validez del modelo se verificó mediante análisis de tolerancia ($10\mu g/m^3$) y mediante pruebas de predicción dividiendo el conjunto de datos en n particiones. Se observó que con suficiente información inicial $n = 3$ la calibración mantuvo errores dentro de la tolerancia, mientras que con menos datos $n = 4$ el error crecía significativamente.

Este estudio demuestra que es posible calibrar sensores IoT de bajo costo con procedimientos simples y reproducibles, aumentando su confiabilidad para complementar las redes oficiales de monitoreo ambiental.

1. Introducción

La contaminación del aire es uno de los principales desafíos ambientales. Dentro de los contaminantes más críticos se encuentra el material particulado (PM, del inglés *Particulate Matter*), cuyas concentraciones elevadas se asocian con impactos en la salud humana, la visibilidad y el clima global [1]. La vigilancia precisa y extensiva es fundamental para la evaluación de riesgos.

Tradicionalmente, la medición de PM se ha realizado mediante instrumentos de referencia de alta precisión. Sin embargo, estos equipos son costosos, requieren mantenimiento especializado y su despliegue a gran escala suele ser limitado. En años recientes, impulsado por la llamada revolución de la internet de las cosas, IoT, se ha facilitado el despliegue masivo de sensores de bajo costo, fáciles de usar y que podrían mejorar la cobertura espacial y por lo tanto podrían complementar o suplantar las redes de monitoreo convencionales y tomar especial relevancia en despertar consciencia al público acerca de la contaminación del aire[3].

No obstante, la respuesta de estos sensores puede afectarse por factores ambientales, propiedades de las partículas o sensibilidades cruzadas. Por lo tanto, la calidad de los datos constituye el principal problema en el uso de los sensores IoT, haciendo que su calibración y recalibración sean etapas esenciales incluso antes del despliegue [2]. Una de las estrategias más comunes de ajuste se basa en comparar estos datos con un patrón de referencia.

El presente trabajo propone un método de calibración basado en el concepto de métrica y de ventanas móviles, una medida que cuantifica la *distancia* entre un conjunto de datos a otro, y que, a su vez, constituye el puente mediante el cual se podrá construir un ajuste a los datos del sensor de baja calidad para la obtención de datos más certeros.

El documento se estructura en tres secciones principales. En la primera de ellas, correspondiente a la metodología, se mencionan los programas utilizados en la labor del procesamiento de la información brindada, y se explica, en líneas generales, los procesos seguidos en cada sección para el análisis y el procesamiento de los datos dados. Posteriormente, en la sección de los resultados, se procede a hablar en más detalle los métodos implementados para cada proceso en específico, se discuten los resultados obtenidos para la determinación de la ventana más óptima, se estudia la calibración de los datos y se evalúa un método por el cual establecer la calidad de dicha calibración. El trabajo finaliza con las conclusiones, donde se busca recopilar, en grandes rasgos, los principales resultados con el trabajo.

2. Metodología

El diseño consistió en la comparación paralela de mediciones de material particulado PM_{25} entre un sensor de bajo costo (IoT) y una estación de referencia ambiental, haciéndose uso de ventanas móviles temporales para establecer la métrica de distancia entre ambos conjuntos. Para todos los cálculos, gráficos y procesamiento de los datos, se utilizó un código de Python con librerías varias.

En primer lugar, se inició por un análisis de los datos dados. Para tal fin, se combinaron los datos del sensor IoT en un solo archivo de Excel. Luego, se subieron ambas bases de datos a un archivo de Jupyter Notebook, y se procedió a realizar un gráfico con ellos. Posteriormente, se observaron los periodos de continuidad y de discontinuidad en ambos conjuntos de datos, y se determinó como necesario hacer una limpieza de los mismos, con la filtración y la eliminación de valores nulos.

Luego, se procedió a plantear distintas ventanas móviles, a fin de ver el comportamiento de la distancia.

Después, se realizó una regresión lineal y se comparó de nuevo con los valores de referencia. Para definir los valores óptimos de ventana y pasos, se probaron distintas configuraciones y se determinó el óptimo según criterios como el tiempo de cómputo, el RMSE y la relación entre la anchura y los pasos para asegurar continuidad.

Para los análisis de alcances se dividió el intervalo temporal de interés y se halló la distancia en cada uno de los intervalos, a fin de saber qué tan buena fue en cada conjunto de datos, con una tolerancia determinada.

Por último, se buscó conocer el carácter predictivo del modelo mediante la elección de un intervalo sobre el que se implementó el modelo lineal. Posterior a ello, se procedió a comparar la predicción del modelo mediante el cálculo de la distancia entre cada subintervalo y el valor de referencia AMB. Se examinó, además, el valor mínimo de particiones necesarias bajo una tolerancia y una definición intervalos concreta sobre la cual se obtuvo una calibración satisfactoria.

3. El experimento y los resultados

En primer lugar, se organizaron los conjuntos de datos de ambas fuentes (AMB Y IoT) en archivos con un mismo formato de Excel, dos columnas asociadas a pares de datos (t , PM_{25}), donde t representaba un instante en el tiempo y PM_{25} la concentración de partículas en suspensión de dimensión $\leq 2,5\mu m$ en ese instante de tiempo. Posteriormente, se procedió a limpiar estos conjuntos de datos eliminando aquellas casillas donde no había información. Luego, se procedió a graficar ambos conjuntos de datos por separado y luego se hizo una superposición (Figura 1).

A partir una inspección. Se observó que presentan una distinta disposición temporal, diferentes puntos de inicio en la recolección de datos acompañado con significativas discontinuidades. Solo a partir del 11 de abril del 2019 existía una correspondencia temporal continua entre ambas fuentes, por este motivo se decidió filtrar datos y utilizar unicamente las observaciones posteriores a esa fecha (Figura 2).




Figura 1: Datos iniciales

3.1. Distancia, ventanas móviles y errores

Para hallar el error; es decir, la *distancia* entre ambos conjuntos es necesario formar pares comparables entre ambos conjuntos. Para esto, ambos datos deben estar en una misma escala temporal, por lo se optó hacer *ventanas móviles*, que consisten en "bloques temporales" que vienen caracterizados por dos parámetros: el ancho de este intervalo (cuánto tiempo tomo) y el paso (cada cuánto avanzo). De tal forma que en cada conjunto para cada intervalo tomado emergerá un único valor, correspondiente al promedio de los datos pertenecientes a dicho intervalo, que se le asignará posición ξ_j , correspondiente al punto medio en el j -ésimo intervalo tomado $[a_j, b_j]$.

La distancia euclidiana no constituye un criterio adecuado en este caso, ya que su magnitud depende directamente de la dimensión de los datos y aumenta con el número de elementos considerados, lo que dificulta la comparación entre diferentes configuraciones. Para superar esta limitación se emplea la raíz del error cuadrático medio (RMSE, por sus siglas en inglés), que normaliza la suma de los errores al dividirla por el número de observaciones y ofrece una medida más representativa del error promedio:




Figura 2: Datos iniciales filtrados

$$\text{RMSE} = \sqrt{\frac{1}{M} \sum_{j=1}^M (f(\xi_j) - \hat{f}(\xi_j))^2}$$

Donde M es el número de ventanas, $f(\xi_j)$ es el valor de referencia en la ventana j , y $\hat{f}(\xi_j)$ es el valor del sensor en la misma ventana.

Para determinar el mejor valor de ventana, se empleó un código con 2 listas: una con distintos dígitos de ventanas y de pasos ($[1, 4, 8, 12, 24]$ y $[0, 5, 2, 4, 12, 24]$, respectivamente). De tal forma que se permutaran los valores y se calculara la distancia Eucladiana, RMSE y tiempo de computo. Se descartaron los casos en los que $\text{ventanas} < \text{pasos}$, dado que se pierden datos.

El análisis de optimización de parámetros de ventanas móviles, presentado en la Tabla 1, demuestra cómo la selección adecuada de ventana y paso impacta simultáneamente en la precisión del sensor y la eficiencia computacional del sistema.

Analizando los resultados de la Tabla 1, se observa que la configuración de **ventana de 4 horas y paso de 2 horas** ofrece un balance adecuado entre precisión y eficiencia. Esta elección permite reducir el error y mantener un valor de RMSE aceptable, al tiempo que los datos se solapan lo suficiente para garantizar continuidad en la serie temporal. Además, el costo computacional se mantiene bajo y, dado que la ventana no es excesivamente grande, se preserva un nivel de detalle que evita la pérdida significativa de variabilidad en la señal. Por estas razones, dicha configuración fue seleccionada como la más conveniente para el análisis posterior.

3.2. Calibración

Una vez seleccionada la configuración óptima de ventana y paso, se procedió a construir un modelo de calibración mediante regresión lineal simple. Para ello, se graficaron los pares comparables $(\hat{f}(\xi_j), f(\xi_j))$. El objetivo de esta etapa es encontrar una función lineal que permita transformar cada lectura del sensor IoT en una estimación cercana al valor de referencia. El modelo adoptado

Cuadro 1: Optimización de ventanas móviles para calibración de sensores: análisis del balance entre precisión y eficiencia.

Conf.	Ventana (h)	Paso (h)	Error ($\mu\text{g}/\text{m}^3$)	RMSE ($\mu\text{g}/\text{m}^3$)	Tiempo (s)
0	1	0.5	637.38	7.33	12.45
1	4	0.5	512.49	5.84	13.29
2	4	1.0	354.85	5.72	5.97
3	4	2.0	250.20	5.70	3.00
4	8	0.5	425.98	4.82	14.17
5	8	1.0	296.19	4.74	7.55
6	8	2.0	209.70	4.75	4.34
7	8	4.0	147.92	4.73	1.90
8	12	0.5	387.02	4.36	15.05
9	12	1.0	270.95	4.32	7.07
10	12	2.0	191.97	4.32	4.23
11	12	4.0	135.25	4.31	1.82
12	12	8.0	93.19	4.21	1.04
13	24	0.5	353.40	3.94	13.20
14	24	1.0	249.04	3.92	6.53
15	24	2.0	176.16	3.92	3.02
16	24	4.0	124.39	3.92	1.51
17	24	8.0	87.98	3.92	0.75
18	24	12.0	71.79	3.92	0.63

es de la forma:

$$f(\xi_j) \approx \alpha \hat{f}(\xi_j)$$

donde α es el parámetro de calibración obtenidos por el método de mínimos cuadrados. De este modo, cada dato IoT puede ajustarse a la escala del sensor oficial mediante la transformación:

$$\hat{y} = \alpha \cdot x$$

con x el valor registrado por el IoT y $\hat{y}$ el valor calibrado.

El ajuste obtenido se muestra en la Figura 3, en la cual se representa la nube de puntos $(\hat{f}(\xi_j), f(\xi_j))$ junto con la recta de calibración hallada.

Este procedimiento constituye la etapa central de la calibración: a partir de la regresión lineal, cada lectura del sensor de bajo costo puede corregirse para aproximarse al comportamiento real de la concentración de material particulado medido por la estación oficial.

Además, se realizó una comparación temporal de ambos conjuntos de datos, pero esta vez con los datos calibrados En la Figura 4




Figura 3: Ajuste lineal de los pares IoT–AMB. La recta representa el modelo de calibración.

3.3. Alcance predictivo, criterios de validez y extensión del modelo

Más allá del proceso de calibración dados dos conjuntos de datos concretos (IoT y AMB), resulta de especial interés poder establecer la *calidad* y la exactitud de la calibración realizada. Por tal motivo, en esta sección se plantea verificar tales parámetros mediante dos consideraciones: su funcionamiento a nivel local y su comportamiento frente a mediciones futuras. Para tal fin, se define una tolerancia, entendida como un valor de referencia que será usado como criterio para la determinación de una buena o mala obtención de error. En el caso particular, se optó por establecer dicho valor en $10 \mu\text{g}/\text{m}^3$, dada la definición del error cuadrático medio (RMSE).

3.3.1. Comportamiento local

En secciones anteriores fue posible evaluar el comportamiento de la calibración mediante el cálculo del error entre los datos de referencia (AMB) y los datos IoT. Sin embargo, la limitación de reducir la calidad de la calibración a un único valor recae en que, por este único método, información sobre cómo un dato particular es calibrado puede llegar a perderse. Una calibración que funciona bien de forma global puede también dar lugar datos singulares ajustados que no concuerdan con los datos de referencia.

En este orden de ideas, se decidió dividir en subintervalos (k partes) a las fechas de evaluación. Luego, se determinó el error en cada una de dichas zonas, y se le comparó con el valor tomado como tolerancia. Se definió como una buena calibración si ninguno de los errores por intervalos sobrepasaba el valor de la tolerancia. El valor de k fue establecido en 250 partes, debido a que se consideró que *anchos* de intervalo pequeños suponían una mayor proximidad al uso de calibración de una medida




Figura 4: Comparación temporal: IoT calibrado y AMB.

concreta. Para lo anterior, se realizó una sección en el código de Python. Adicionalmente, se optó por añadir en la Figura 5 una visualización de cómo luce dicha partición.

De esta manera, se logró apreciar que para la configuración de ventana y pasos elegida (de 4 horas y 2 horas respectivamente), la calibración era válida. Igualmente, se pudo notar un error máximo del $5,508 \mu g/m^3$ y uno mínimo de $2,015 \mu g/m^3$.




Figura 5: División temporal para $k = 250$ intervalos

3.3.2. Extensión del modelo

Ahora bien, otro aspecto de especial relevancia al momento de evaluar la calibración es el que corresponde a la verificación de su funcionamiento ante mediciones futuras. Una estrategia para determinar lo anterior consiste en tomar una parte de los datos, implementar el modelo lineal y comparar la predicción del modelo con las mediciones próximas. Así entonces, la determinación de la cantidad de partes, n , sobre las que los datos son divididos para hacer la nueva regresión cobra un

papel importante, en cuanto a que es de gran utilidad para establecer la mínima de datos necesarios para poder tener un modelo considerado como *bueno* dado el valor de la tolerancia.

En la Figura 6 es posible observar algunos modelos donde se utilizan diferentes cantidades de datos para hacer la calibración. El valor n representa la cantidad de partes sobre las cuales se dividió la franja de los datos, y se usó únicamente la primera de dichas franjas para implementar el modelo. Como será posible apreciar, entre menor es la cantidad de datos (o equivalentemente, mayor es el valor de n), se posee de mayores discrepancias entre los datos que conforman las mediciones del sensor AMB y los del sensor IoT calibrado.




Figura 6: Comparación de la calibración del sensor IoT para diferentes valores de n

Posteriormente, se exploraron variaciones en n para poder establecer el mínimo de divisiones sobre las cuales, para $k = 250$ y bajo la tolerancia de $10\mu g/m^3$ establecida anteriormente, se obtuvieron resultados satisfactorios. Resultó que, en este régimen, la utilización de una tercera parte de los datos ($n = 3$) es el límite sobre el cual es posible obtener tal resultado, pues cuando se utiliza la cuarta parte ($n = 4$), se obtienen 4 valores que sobrepasan el valor establecido. Resulta interesante mencionar la importancia del número de intervalos k sobre los que se evalúa la tolerancia, pues cambios sobre este valor son capaces de modificar en gran medida los resultados obtenidos. En particular, cuando se reemplazó a k por 200 se encontró una limitación computacional: el tiempo de

ejecución se incrementó de forma considerable y, bajo la misma tolerancia, no fue posible determinar un valor mínimo de n que cumpliera el criterio

4. Conclusiones y Recomendaciones

El presente trabajo presenta un aporte metodológico en el ámbito de la calibración de sensores IoT para el monitoreo de material particulado PM_{25} , en el que se propuso el uso de ventanas móviles y métricas de error para optimizar la precisión y eficacia computacional. Su importancia radica en la posibilidad de mejorar la confiabilidad de estos dispositivos. Facilitando su uso complementario en las redes de monitoreo directas

- La determinación del valor óptimo de ventana no depende únicamente del error, también depende de cosas como el tiempo de cómputo o una cantidad de pasos que garanticen solapamiento.
- Se evidenció que ventanas muy pequeñas producen una mayor sensibilidad a la variabilidad local, pero incrementan la inestabilidad de la calibración y el costo computacional; mientras que ventanas muy grandes suavizan la variabilidad y reducen la precisión local, aunque son más estables globalmente.
- El carácter para establecer la calidad de la calibración a nivel local y la cantidad mínima de datos para el alcance de una calibración satisfactoria depende en gran medida del *ancho* del intervalo sobre el cual se evalúa la distancia entre los datos AMB y los de IoT calibrados: intervalos más finos permiten identificar de manera más exacta los rangos donde el modelo pierde capacidad predictiva.

Finalmente, se resalta que la propuesta metodológica no busca reemplazar las estaciones de referencia, sino complementarlas: al caracterizar los sensores IoT bajo ventanas y tolerancias bien definidas, se mejora su confiabilidad y se abre la posibilidad de ampliar la cobertura espacial de las redes de monitoreo ambiental.

5. Referencias

Referencias

- [1] Steinle S, Reis S, Sabel CE, Semple S, Twigg MM, Braban CF, Leeson SR, Heal MR, Harrison D, Lin C, Wu H (2015) Personal exposure monitoring of $PM_{2.5}$ in indoor and outdoor microenvironments. *Sci Total Environ* 508:383–394. <https://doi.org/10.1016/j.scitotenv.2014.12.003>
- [2] Yang Wang, Jiayu Li, He Jing, Qiang Zhang, Jingkun Jiang & Pratim Biswas (2015) Laboratory Evaluation and Calibration of Three Low-Cost Particle Sensors for Particulate Matter Measurement, *Aerosol Science and Technology*, 49:11, 1063-1077, DOI: 10.1080/02786826.2015.1100710

- [3] Rai AC, Kumar P, Pilla F, Skouloudis AN, Di Sabatino S, Ratti C, Yasar A, Rickerby D (2017) End-user perspective of low-cost sensors for outdoor air pollution monitoring. *Sci Total Environ* 607–608:691–705. <https://doi.org/10.1016/j.scitotenv.2017.06.266>